

統計計算の基礎

Y-teraya

2025年11月2日

概要

本資料は、統計の基礎的な計算方法をまとめたものである。実験計画法を主として扱い、実務で直結する内容（Excel 関数など）を備忘録として記しておく。ほか、線形代数や微分積分も取り扱う。

また、総和 \sum の記号に苦手意識を持っている人も多いので、理解して欲しい重要な式のみ \sum 無しで表現した式も併記している。

目次

第 I 部 初歩的な計算	1
1 指数 Exponent	1
1.1 累乗 Repeat multiplication	1
1.2 0乗とマイナス乗	1
第 II 部 数学の記法と用語	2
第 III 部 統計のデータ	3
2 代表値 Average	3
2.1 平均値 Mean	3
2.2 中央値 Median	4
2.3 最頻値 Mode	4
2.4 最大値 Maximum・最小値 Minimum	5
3 散布度 Dispersion	5
3.1 分散 Variance・標準偏差 Standard deviation	5
3.2 範囲 Range	6

第Ⅳ部 データのイメージ	7
4 スカラー Scalar とベクトル Vector	7
4.1 ベクトルの加減法	8
4.2 単位ベクトル	8
4.3 ベクトルの成分表示	8

[青文字](#)をクリックすると、対応したページに遷移します。

留意事項

1. 色付き文字やハイライトは重要事項または強調箇所である。
2. 自身の好み（独断と偏見）で作成しているため、旧字体や座標を行列で記載している箇所がある。
3. 本資料の著作権は、[CC BY-NC-SA 4.0](#) を適応する。

第Ⅰ部

初步的な計算

1 指数 Exponent

1.1 累乗 Repeat multiplication

ある数 a を n 回掛けたものを a の n 乗といい a^n と書く。 a を底、 n を指数という。特に、指数が正の整数 ($n > 0^{*1}$) のとき累乗といい、それ以外の場合は、べき乗 Exponent という。

指数法則 Exponential laws は、定義より自明ではあるものの法則^{*2}として紹介されていることが多いので、法則として扱う。底を a ($a \in Z^{*1}$)、指数を m, n ($m, n \in R^{*1}$) としたとき、以下の 2 法則が成立する。

$$a^m \times a^n = \underbrace{a \times a \times a \times \cdots \times a}_{m\text{個}} \cdot \underbrace{a \times a \times \cdots \times a}_{n\text{個}} = a^{m+n} \quad (1.1)$$

これは単純。 a を m 回掛けたものと a を n 回掛けたものを全て掛けたら、 a を $m + n$ 回掛けたものと同じになる。

$$(a^m)^n = \underbrace{a^m \times a^m \times \cdots \times a^m}_{n\text{個}} = a^{m \times n} \quad (1.2)$$

少し捉えにくいかもしれない。 a を m 回掛けたものを n 回掛けたら、それは a を $m \times n$ 回掛けたものと同じになる。ただ、それだけの話。

(1.1) 式、(1.2) 式は特に暗記しなくても、累乗がどういうものだったか？を考えれば簡単に分かる。

1.2 0乗とマイナス乗

^{*1} 第Ⅱ部の数学の記法と用語で取り扱う。

^{*2} 一般には、経験則から導かれた証明できない事象のことである。今回の場合は、累乗の定義から自明であり説明するまでもないだろう。

第 II 部

数学の記法と用語

第 III 部

統計のデータ

2 代表値 Average

データ全体を分布中心のデータ 1 つで表したもの代表値という。主に 3 つの値のことを指し、平均値 Mean, 中央値 Median, 最頻値 Mode である。ただし、これらの値がデータの代表ではない可能性もあるため、扱うときには必ずデータの代表として機能しているのか確認する必要がある [4, 5]。

2.1 平均値 Mean

主に算術平均のことを指す。全データを合計し、データの数で割ることで求められる。平均値を \bar{x} ^{*3}、データ数を n 、各データを x_k とすると、以下である^{*4}。

$$\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k = \frac{x_1 + x_2 + \cdots + x_n}{n} \quad (2.1)$$

メリット^[2] 全てのデータを考慮できる。

デメリット 外れ値に弱い。

エクセル =AVERAGE(Cell₁: Cell₂)

【余談: 平均にもいろんな種類がある！^[1]】

上記では、算術平均（相加平均）を取り扱った。一般に平均と言わればこの算術平均だと思えばよい。ただ、他にも場合によっては使える平均があるので紹介する。

2.1.1 幾何平均（相乗平均）

算術平均は足し算においての平均であったが、これは掛け算においての平均である。平均値を G 、データ数を n 、各データを x_k とすると、以下である^a。

$$G = \left(\prod_{k=1}^n x_k \right)^{\frac{1}{n}} = \sqrt[n]{x_1 \times x_2 \times \cdots \times x_n} \quad (2.2)$$

主に、成長率や増加率など比率や割合で変化する数の平均を算出したいときに用いる。

^{*3} μ と置くこともある。

^{*4} \sum の計算は、基本的に $1 \leq k \leq n$ ($k \in \mathbb{Z}$) の範囲内での総和を示す記号である。 \sum の下に書いてある数字から、上に書いてある数字までをカウントアップして足したものである。

2.1.2 調和平均

調和平均は、一度逆数にしたデータの算術平均のことである。平均値を H 、データ数を n 、各データを x_k とすると、以下である。

$$H^{-1} = \frac{1}{n} \left(\sum_{k=1}^n \frac{1}{x_k} \right) = \frac{\frac{1}{x_1} + \frac{1}{x_2} + \cdots + \frac{1}{x_n}}{n} \quad (2.3)$$

主に、平均速度や並列接続時の抵抗、直列接続時のコンデンサなど比率で表わされる数の平均を算出したいときに用いる。

^a \prod の計算は \sum の足し算を掛け算に変えたものである、基本的に $1 \leq k \leq n$ ($k \in \mathbb{Z}$) の範囲内の総積を示す記号である。 \prod の下に書いてある数字から、上に書いてある数字までをカウントアップして掛けたものである。

2.2 中央値 Median

データを大きさの順に並べた際の、真ん中の値を指す。例えば、データの集合 A を以下の通りに設定する。

$$A = \{x_k | 1 \leq k \leq 5\} \quad (2.4)$$

数列 x_k が降べきの順に並んでいるとすると、集合 A の中央値は x_3 である。

メリット [2] 外れ値に強い。

デメリット 全てのデータを十分に考慮に入れることができない。

エクセル =MEDIAN(Cell₁: Cell₂)

2.3 最頻値 Mode

データの集合内で、同じデータが存在する場合がある。その同じデータが最も出現する値を指す。例えば、データの集合 B を以下の通りに設定する。

$$B = \{x_k | 1 \leq k \leq 5\} \quad (x_2 = x_3) \quad (2.5)$$

このとき、集合 B の最頻値は x_2, x_3 である。

メリット [2] 外れ値に強い。

デメリット 1つに決まらないことがある。また、サンプルサイズが少ないと使えない。

エクセル =MODE.SNGL(Cell₁: Cell₂)

2.4 最大値 Maximum・最小値 Minimum

データの集合内で、一番大きい値を最大値、小さい値を最小値という。例えば、集合 A 、式(1.2)を基にして考える。このとき、最大値は x_5 、最小値は x_1 である。

エクセル（最大値）=MAX(Cell₁: Cell₂)

エクセル（最小値）=MIN(Cell₁: Cell₂)

3 散布度 Dispersion

3.1 分散 Variance・標準偏差 Standard deviation

各データと平均との差の平均である。一般にデータのバラつきを表す。分散を s^2 ⁵、データ数を n 、各データを x_k とすると、以下である。

$$s^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n} \quad (3.1)$$

標準偏差はこの2乗を外したもののことである。すなわち、分散 s^2 をルート $\sqrt{}$ に入れたものである。そのため、標準偏差を s ⁶ とすると以下である。

$$s = \sqrt{\frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2} \quad (3.2)$$

【余談: なぜ2乗した誤差を考えるのか? [3]】

平均との差であれば、絶対値を用いれば良いと考えられる。絶対値で計算する平均偏差と呼ばれるものを紹介する。平均偏差は以下で求められる。

$$MAE = \frac{1}{n} \sum_{k=1}^n |x_k - \bar{x}| \quad (3.3)$$

ただし、これは数学的に扱いにくい。以下に3点挙げる。

1. 絶対値は函数として微分可能でなく扱いづらい。
2. 場合分けが必要になることがある。

⁵ σ^2 と置くこともある。

⁶ σ と置くこともある。

$$3. \bar{x} \neq \arg \min_{\bar{x}} \sum_{k=1}^n |x_k - \bar{x}| \text{ である.}$$

特に 3 つ目が問題であるが、話が難しくなるので詳しくは参考文献の記事を読んで欲しい。

3.2 範囲 Range

単に最大値と最小値の差である。例えば、集合 A 、式 (1.2) を基にして考える。このとき、範囲は $x_5 - x_1$ である。

第 IV 部 データのイメージ

4 スカラー Scalar とベクトル Vector

スカラーは 1 つの数であり、ベクトルは 2 つ以上の数を束ねたものである。そしてベクトルの表現として文字の上に矢印 \vec{x} を描いてベクトルを表現する。ただ、非常に見づらくなりやすいという欠点がある。そのため、大学以降ではスカラーはそのまま、ベクトルは太字 x または 2 重文字 \bar{x} (文字に余計な線を 1 つ入れるだけ) で表現する。よく、スカラーは大きさだけ持つ量で、ベクトルは大きさと向きも持つ量と理解している人も多い。それは何故か？

$$A = 2$$

図 1: スカラー量

$$\mathbf{B} = (2 \quad 1 \quad 3)$$

図 2: ベクトル量

スカラーのイメージは、1 次元である。すなわち、 x 軸だけの数直線を考えると单なる大きさにすぎない。次にベクトルのイメージは、2 次元や 3 次元である。 x 軸だけでは、大きさしか表せなかったのに対し、数を束にすることで 2 つ目以降の数によって方向が決まる。




図 3: スカラーのイメージ




図 4: ベクトルのイメージ

簡単に説明すると、スカラーは 1 つの数であり、ベクトルは数と数の組^{*7}である。ベクトルは方向を表すことから、基本的に矢印で表現することが多い。そのとき大きさは、矢印の長さで表す。

^{*7}厳密には、線形空間の元であるが、話が難しくなるので本資料では触れないことにする。線形空間の元として考えると、多項式もベクトル、函数もベクトル、微分方程式の解もベクトルとして捉えられる。これらのように、この世界にはベクトルでありふれている！

また、それぞれの量のことを表現するとき、それに名前を付けてスカラー量、ベクトル量という。

4.1 ベクトルの加減法

スカラーはそのまま加減乗除できるが、ベクトルはそう上手くいかない。ベクトルの乗法には内積と外積の2種類あり、除法はできない。分かりやすい加減法から説明する。

言葉で説明するなら、矢印の終点ともう一方の矢印の始点を合わせ、1つの折れ線矢印と見なして始点と終点を線で結ぶ。減法の場合は、矢印を逆にしてから足す。矢印が逆のベクトルを逆ベクトルという。

ほかに始点同士を揃えて平行四辺形にする方法もあり、運動方程式を解く際の分力を求めるときに最適である。

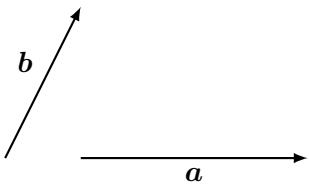
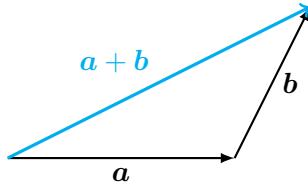
図 5: \mathbf{a} と \mathbf{b} 

図 6: 三角形を作る方法

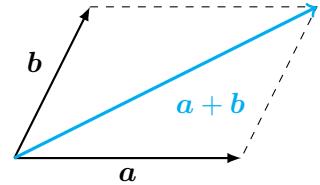


図 7: 平行四辺形を作る方法

4.2 単位ベクトル

ユークリッド空間（実数を n 個並べた全体の集合）において、3つの直交座標をそれぞれ x 軸、 y 軸、 z 軸とする。そのなかで大きさを「1」に仕立てたベクトルを単位ベクトルという。（単位○○は基本的に、○○の大きさを「1」に仕立てたもののことである。）

また、 x 軸と平行な単位ベクトルを \mathbf{i} 、 y 軸と平行な単位ベクトルを \mathbf{j} 、 z 軸と平行な単位ベクトルを \mathbf{k} とする。

4.3 ベクトルの成分表示

単位ベクトルと係数倍を用いて、一般にベクトルを次のような式で表せる。

$$\mathbf{a} = A\mathbf{i} + B\mathbf{j} + C\mathbf{k} \quad (4.1)$$

また、係数を座標のように表して、

$$\mathbf{a} = (A \quad B \quad C) \quad (4.2)$$

とも表せる。

参考文献

- [1] 技術でブランドを支える ケムファク. 知っておきたい様々な平均値. <https://chem-fac.com/average>, 2024. アクセス日: 2025-11-02.
- [2] 高校数学の美しい物語. 平均値, 中央値, 最頻値の求め方といくつかの例. <https://manabitimes.jp/math/985>, 2023. アクセス日: 2025-10-28.
- [3] 数学の景色. データの分散・標準偏差の定義・具体例・性質まとめ. <https://mathlandscape.com/variance>, 2023. アクセス日: 2025-10-28.
- [4] 内田誠一. 2-1-2. データの分布と代表値. <https://mi.u-tokyo.ac.jp/consortium/pdf/2-1-2.pdf>, 2020. アクセス日: 2025-10-28.
- [5] 内田誠一. 2-1-3. 代表値の性質の違い. <https://mi.u-tokyo.ac.jp/consortium/pdf/2-1-3.pdf>, 2020. アクセス日: 2025-10-28.

索引

Average, 3	中央値, 3, 4 代表値, 3
Dispersion, 5	
Maximum, 5	分散, 5
Mean, 3	外れ値, 3, 4
Median, 3, 4	平均値, 3, 4
Minimum, 5	
Mode, 3, 4	散布度, 5
Range, 6	最大値, 5, 6
Standard deviation, 5	最小値, 5, 6
Variance, 5	最頻値, 3, 4
	標準偏差, 5
	算術平均, 3
	範囲, 6